



FACULTAD DE MATEMÁTICAS
PONTIFICIA UNIVERSIDAD
CATÓLICA DE CHILE

Análisis del Artículo:

*Explainable Artificial Intelligence for Suicide Risk
Assessment Using Register Data*

EYP3507: Bioestadística

Integrantes:

Esteban D. Román

William Mora

Pontificia Universidad Católica de Chile
Facultad de Matemáticas

14 de junio de 2026

Resumen

Este trabajo analiza el artículo de Tang et al. (2024), que evalúa el uso de Inteligencia Artificial Explicable (XAI) para predecir el riesgo de suicidio a partir de datos tabulares de registro médico. La motivación de los autores parte de una limitación reconocida en el área: las herramientas tradicionales de evaluación del riesgo, basadas mayoritariamente en escalas autoinformadas y juicio clínico, presentan un valor predictivo positivo bajo y resultan insuficientes para estratificar con precisión a los pacientes (Tang et al., 2024, Introducción). Frente a ello, el artículo propone combinar modelos de aprendizaje automático con un marco de explicabilidad que permita a los profesionales de la salud mental comprender y confiar en las predicciones.

El objetivo de este informe es responder tres preguntas sobre dicho artículo:

- (i) *La distinción conceptual entre Inteligencia Artificial y Estadística.*
- (ii) *Si el artículo separa de manera explícita la predicción de la explicación.*
- (iii) *Qué evidencia respalda que el patrón identificado por el modelo corresponde efectivamente al fenómeno estudiado y no a un mero artefacto de los datos.*

Para orientar la lectura, abordaremos estas preguntas distinguiendo con cuidado entre describir patrones, *predecir* y *explicar*. En la **P1** sostendremos que, en **Tang et al. (2024)**, IA y Estadística no aparecen como rivales: se diferencian por el énfasis (optimizar la *predicción* frente a interpretar relaciones) y la *XAI* opera como un mecanismo de traducción entre ambos lenguajes. En la **P2** defenderemos que el artículo no confunde predicción con explicación, pero sí emplea un concepto de explicación acotado: *SHAP* explica el modelo (qué variables empujan la predicción), no el fenómeno (por qué ocurre el suicidio). En la **P3** concluiremos que la evidencia aportada justifica sobre todo que el patrón es estable y útil para predecir dentro del propio marco de datos y modelo; queda abierta, en cambio, la justificación teórico-causal de ese patrón (y, por tanto, su interpretación como mecanismo del fenómeno) más allá del conjunto de datos analizado.

Los datos provienen del historial clínico de pacientes del Colombo South Teaching Hospital (Sri Lanka) y conforman un conjunto balanceado de 1000 registros (500 casos positivos y 500 negativos) con 19 variables predictoras de naturaleza numérica y categórica (Tang et al., 2024, Método, p. 8). Sobre esta base, el artículo aplica dos técnicas de aumento de datos (CTGAN y SMOTENC) para expandir la muestra de entrenamiento y mitigar el sobreajuste, y entrena seis modelos de Machine Learning (Regresión Logística, Árbol de Decisión, Random Forest, SVM, Perceptrón y XGBoost). Random Forest obtiene el mejor desempeño, alcanzando un AUC de 97,05 % tras el aumento de datos (Tang et al., 2024, Tabla 1). Para interpretar el modelo, los autores recurren a los valores SHAP, que identifican la ira, la depresión y el aislamiento social como los predictores principales del riesgo de suicidio (Tang et al., 2024, Fig. 6b).

Concluimos que el artículo trata la XAI como un puente entre la capacidad predictiva del aprendizaje automático y la vocación explicativa de la Estadística. No obstante, conviene precisar el alcance de ese puente: la “explicación” que ofrece SHAP es una atribución de importancia a las variables (es decir, una descripción de cómo cada atributo contribuye a la salida del modelo), y no una explicación causal del suicidio. El método identifica asociaciones predictivas, pero no establece mecanismos causales ni descarta confusores, distinción que resulta central para las tres preguntas que guían este informe.

Pregunta 1: ¿Qué distingue conceptualmente a la Inteligencia Artificial o «IA» de la Estadística en este artículo?

El artículo no presenta la Inteligencia Artificial (IA) y la Estadística como disciplinas opuestas, sino que las distingue por su finalidad. La Estadística busca inferir asociaciones e interpretar las relaciones entre variables, mientras que la IA, a través del aprendizaje automático (ML), prioriza la predicción de un resultado a partir de datos históricos.

En el estudio, la Estadística se materializa en el análisis de correlación de Spearman y en el mapa de calor, herramientas orientadas a cuantificar y ordenar la asociación entre variables; por ejemplo, la fuerte correlación entre el suicidio y los problemas de ira, el aislamiento social o la depresión (Tang et al., 2024, Fig. 3). Su valor reside en la interpretabilidad directa: cada coeficiente revela la dirección y la fuerza de una relación sin requerir explicaciones adicionales.

La IA, en cambio, se expresa en modelos como Random Forest y XGBoost, evaluados por su desempeño predictivo ($AUC = 97,05\%$, F1 y precisión; Tang et al., 2024, Tabla 1). Estos modelos capturan relaciones complejas y no lineales que las técnicas clásicas no logran modelar (el artículo advierte que los métodos matemáticos tradicionales producen resultados menos precisos ante la complejidad del comportamiento humano), pero operan como cajas negras de baja interpretabilidad.

Esta tensión no es exclusiva del artículo. Breiman (2001) describió «dos culturas» del modelamiento: la del *modelo de datos* estadística clásica, orientada a inferir la relación entre variables y la del *modelo algorítmico* ML, orientado a predecir con precisión. Shmueli (2010) formalizó esta diferencia entre *explanatory modeling* y *predictive modeling*. El artículo de Tang et al. (2024) opera en la segunda cultura y emplea SHAP (Lundberg & Lee, 2017), fundamentado en los valores de Shapley de la teoría de juegos cooperativos, para reintroducir interpretabilidad.

El puente entre ambos enfoques es, precisamente, la IA Explicable (XAI). Mediante SHAP, el artículo reintroduce la interpretabilidad en los modelos predictivos, asignando a cada variable una contribución positiva o negativa a la predicción individual. Así, la capacidad predictiva de la IA converge con la vocación explicativa de la Estadística.

La distinción es, por tanto, funcional más que tajante. Varios de los “modelos de ML” empleados (regresión logística, Lasso y Ridge) son métodos estadísticos clásicos, y el propio SHAP se funda en la teoría de juegos cooperativos. El artículo trata la IA como una extensión predictiva de la Estadística, no como su antítesis.

Pregunta 2

Dado que muchos enfoques de Machine Learning priorizan el rendimiento predictivo, ¿el artículo distingue entre predicción y explicación, o asume que ambos son equivalentes?

El artículo distingue de forma implícita entre predicción y explicación, pero no las define ni las contrasta explícitamente. Esta omisión genera una ambigüedad que conviene precisar: Tang et al. (2024) operan sobre la predicción y emplean la explicabilidad (XAI) como interpretación del modelo, no como explicación causal del fenómeno.

Para fijar los términos, adoptamos la distinción de Shmueli (2010) entre *explanatory modeling* y *predictive modeling*. Explicar consiste en contrastar una hipótesis causal sobre el mecanismo que genera los datos; predecir consiste en estimar con precisión valores no observados, sin requerir que el modelo represente dicho mecanismo. Breiman (2001) formula la misma tensión como “dos culturas”: el *modelo de datos*, orientado a inferir la relación entre variables, y el *modelo algorítmico*, orientado a minimizar el error de predicción. Ambos autores coinciden en que un buen desempeño predictivo no garantiza validez explicativa.

Bajo este marco, el artículo se inscribe claramente en la cultura predictiva. Su criterio de éxito es el desempeño ($AUC = 97,05\%$ con Random Forest; Tang et al., 2024, Tabla 1), no la verificación de una hipótesis sobre las causas del suicidio. La incorporación de SHAP (Lundberg & Lee, 2017) no altera esta orientación: los valores SHAP atribuyen a cada variable su contribución a la salida del modelo, es decir, explican *el modelo*, no *el fenómeno*. Se trata de interpretabilidad (saber qué variables empujan la predicción) y no de explicación causal (saber por qué ocurre el suicidio).

La distinción es relevante porque las atribuciones SHAP son asociativas y dependen del modelo y de los datos que lo entrenan. Como advierte Pearl (2009), la correlación no implica causalidad: sin un diseño que controle confusores o intervenga sobre las variables, no es posible elevar una asociación predictiva a relación causal. Por ello, que la ira, la depresión y el aislamiento social sean predictores importantes (Tang et al., 2024, Fig. 6b) no equivale a afirmar que los causen; podrían ser síntomas, consecuencias o efectos de un confusor común.

En conclusión, el artículo no asume que predicción y explicación sean equivalentes, pero tampoco delimita sus alcances. Su aporte es predictivo y la XAI cumple una función interpretativa sobre el modelo; la explicación causal del fenómeno, en el sentido de Shmueli (2010) y Pearl (2009), queda fuera de su diseño. La equivalencia aparente entre ambos términos se disuelve al reconocer que SHAP explica una función, no un mecanismo.

Pregunta 3: En muchas aplicaciones de Machine Learning, las relaciones identificadas por los modelos están guiadas principalmente por patrones presentes en los datos y por objetivos predictivos, sin una justificación teórica explícita del fenómeno subyacente. ¿Qué evidencia entrega el artículo para justificar que el patrón identificado corresponde al fenómeno estudiado?

Para responder esta pregunta, se evaluarán todas las conclusiones obtenidas relacionadas con el fenómeno investigado y la base que llevó a cada una de ellas.

Primera conclusión: *Quienes fallecen por suicidio tienden a ser personas con trastornos o enfermedades.* Esta conclusión se obtiene mediante una nube de palabras formada con la base de datos; no se entrega otro tipo de información que justifique dicha inferencia.

Segunda conclusión: *Las personas con altos ingresos y una ocupación respetable presentan menores tasas de suicidio.* Se llegó a esta conclusión a través de un gráfico de barras elaborado con la base de datos, el cual mostraba que las personas desempleadas tienen el mayor riesgo de suicidio, mientras que el personal de seguridad y los policías presentan el menor riesgo. También se menciona que la conclusión obtenida coincide con los resultados de otros estudios, aunque no se profundiza en los motivos de la existencia del patrón encontrado; solo se señala que este existe.

Posteriormente, mediante modelos de predicción, la matriz de correlación y el cálculo de los valores *SHAP*, se obtiene que factores como tener problemas de ira o depresión pueden aumentar el riesgo de suicidio de los individuos. Por otro lado, factores como un alto nivel educativo disminuyen dicho riesgo. Los resultados obtenidos coinciden con las conclusiones anteriores, con la diferencia de que fueron alcanzados mediante métodos más complejos. Sin embargo, a pesar de ofrecer mayor evidencia a través de los valores *SHAP*, estos se calculan utilizando la misma base de datos, por lo que continúa el patrón de basar las conclusiones únicamente en ella.

Limitaciones y observaciones: El análisis se limita a observar los registros y explicarlos mediante distintos modelos predictivos, sin ampliar su perspectiva. Ninguno de los apartados que presenta estas conclusiones las justifica desde un punto de vista psicológico o psiquiátrico, el cual podría complementar los resultados y mejorar la aplicación de estos modelos en el área médica. **Es importante mencionar**, por ello, que el artículo reconoce esta limitación y concluye que los modelos de predicción deberían ser utilizados en conjunto con el asesoramiento médico.

Referencias

1. Breiman, L. (2001). *Statistical Modeling: The Two Cultures*. *Statistical Science*, 16(3), 199–231.
<https://projecteuclid.org/journals/statistical-science/volume-16/issue-3/Statistical-Modeling--The-Two-Cultures-with-comments-and-a/10.1214/ss/1009213726.pdf>
2. Shmueli, G. (2010). *To Explain or to Predict?* *Statistical Science*, 25(3), 289–310.
<https://www.stat.berkeley.edu/~aldous/157/Papers/shmueli.pdf>
3. Lundberg, S. M., & Lee, S.-I. (2017). *A Unified Approach to Interpreting Model Predictions*. *Advances in Neural Information Processing Systems* (NeurIPS).
<https://proceedings.neurips.cc/paper/7062-a-unified-approach-to-interpreting-model-predictions.pdf>
4. Pearl, J. (2009). *Causality: Models, Reasoning, and Inference* (2.^a ed.). Cambridge University Press.
https://archive.illc.uva.nl/cil/uploaded_files/inlineitem/Pearl_2009_Causality.pdf
5. Chawla, N., Bowyer, K., Hall, L., & Kegelmeyer, W. (2002). *SMOTE: Synthetic Minority Over-sampling Technique*. *Journal of Artificial Intelligence Research*, 16, 321–357.
<https://arxiv.org/pdf/1106.1813>
6. Xu, L., Skoularidou, M., Cuesta-Infante, A., & Veeramachaneni, K. (2019). *Modeling Tabular Data using Conditional GAN*. *Advances in Neural Information Processing Systems* (NeurIPS).
<https://arxiv.org/pdf/1907.00503>
7. Tang, X., et al. (2024). *Analysis and evaluation of explainable artificial intelligence on suicide risk assessment*. *Scientific Reports*, 14, 6163.
<https://www.nature.com/articles/s41598-024-53426-0.pdf>