



FACULTAD DE MATEMÁTICAS
PONTIFICIA UNIVERSIDAD
CATÓLICA DE CHILE

Análisis del Artículo:

*Analysis and Evaluation of Explainable Artificial Intelligence
on Suicide Risk Assessment*

EYP3507: Bioestadística

Integrantes:

Esteban D. Román Soto
William E. Mora Estrada

Pontificia Universidad Católica de Chile
Facultad de Matemáticas

14 de junio de 2026

Resumen

Este trabajo analiza el artículo de Tang et al. (2024), que evalúa el uso de Inteligencia Artificial Explicable (XAI) para predecir el riesgo de suicidio a partir de datos tabulares de registro médico. La motivación de los autores parte de una limitación reconocida en el área: las herramientas tradicionales de evaluación del riesgo, basadas mayoritariamente en escalas autoinformadas y juicio clínico, presentan un valor predictivo positivo bajo y resultan insuficientes para estratificar con precisión a los pacientes (Tang et al., 2024, Introducción). Frente a ello, el artículo propone combinar modelos de aprendizaje automático con un marco de explicabilidad que permita a los profesionales de la salud mental comprender y confiar en las predicciones.

El objetivo de este informe es responder tres preguntas sobre dicho artículo:

- (i) *La distinción conceptual entre Inteligencia Artificial y Estadística.*
- (ii) *Si el artículo separa de manera explícita la predicción de la explicación.*
- (iii) *Qué evidencia respalda que el patrón identificado por el modelo corresponde efectivamente al fenómeno estudiado y no a un mero artefacto de los datos.*

Para orientar la lectura, abordaremos estas preguntas distinguiendo con cuidado entre describir patrones, *predecir* y *explicar*. En la **P1** sostendremos que, en **Tang et al. (2024)**, IA y Estadística no aparecen como rivales: se diferencian por el énfasis (optimizar la *predicción* frente a interpretar relaciones) y la *XAI* opera como un mecanismo de traducción entre ambos lenguajes. En la **P2** argumentaremos que la respuesta depende de la definición de “explicar” que se adopte: bajo una definición expositiva (hacer la información perceptible), predicción y explicación son funcionalmente equivalentes; bajo una definición causal (dar a conocer el motivo de algo), difieren, pues *SHAP* explica el modelo (qué variables empujan la predicción) pero no el fenómeno (por qué ocurre el suicidio). En la **P3** concluiremos que la evidencia aportada justifica sobre todo que el patrón es estable y útil para predecir dentro del propio marco de datos y modelo; queda abierta, en cambio, la justificación teórico-causal de ese patrón (y, por tanto, su interpretación como mecanismo del fenómeno) más allá del conjunto de datos analizado.

Los datos provienen del historial clínico de pacientes del Colombo South Teaching Hospital (Sri Lanka) y conforman un conjunto balanceado de 1000 registros (500 casos positivos y 500 negativos) con 19 variables predictoras de naturaleza numérica y categórica (Tang et al., 2024, Método, p. 8). Sobre esta base, el artículo aplica dos técnicas de aumento de datos (CTGAN y SMOTENC) para expandir la muestra de entrenamiento y mitigar el sobreajuste, y entrena seis modelos de Machine Learning (Regresión Logística, Árbol de Decisión, Random Forest, SVM, Perceptrón y XGBoost). Random Forest obtiene el mejor desempeño, alcanzando un AUC de 97,05 % tras el aumento de datos (Tang et al., 2024, Tabla 1). Para interpretar el modelo, los autores recurren a los valores SHAP, que identifican la ira, la depresión y el aislamiento social como los predictores principales del riesgo de suicidio (Tang et al., 2024, Fig. 6b).

Concluimos que el artículo trata la XAI como un puente entre la capacidad predictiva del aprendizaje automático y la vocación explicativa de la Estadística. No obstante, conviene precisar el alcance de ese puente: la “explicación” que ofrece SHAP es una atribución de importancia a las variables (es decir, una descripción de cómo cada atributo contribuye a la salida del modelo), y no una explicación causal del suicidio. El método identifica asociaciones predictivas, pero no establece mecanismos causales ni descarta confusores, distinción que resulta central para las tres preguntas que guían este informe.

Pregunta 1

¿Qué distingue conceptualmente a la Inteligencia Artificial o «IA» de la Estadística en este artículo?

El artículo no presenta la Inteligencia Artificial (IA) y la Estadística como disciplinas opuestas, sino que las distingue por su finalidad. La Estadística busca inferir asociaciones e interpretar las relaciones entre variables, mientras que la IA, a través del aprendizaje automático (ML), prioriza la predicción de un resultado a partir de datos históricos.

En el estudio, la Estadística se materializa en el análisis de correlación de Spearman y en el mapa de calor, herramientas orientadas a cuantificar y ordenar la asociación entre variables; por ejemplo, la fuerte correlación entre el suicidio y los problemas de ira, el aislamiento social o la depresión (Tang et al., 2024, Fig. 3). Su valor reside en la interpretabilidad directa: cada coeficiente revela la dirección y la fuerza de una relación sin requerir explicaciones adicionales.

La IA, en cambio, se expresa en modelos como Random Forest y XGBoost, evaluados por su desempeño predictivo ($AUC = 97,05\%$, F1 y precisión; Tang et al., 2024, Tabla 1). Estos modelos capturan relaciones complejas y no lineales que las técnicas clásicas no logran modelar (el artículo advierte que los métodos matemáticos tradicionales producen resultados menos precisos ante la complejidad del comportamiento humano), pero operan como cajas negras de baja interpretabilidad.

Esta tensión no es exclusiva del artículo. Breiman (2001) describió «dos culturas» del modelamiento: la del *modelo de datos* estadística clásica, orientada a inferir la relación entre variables y la del *modelo algorítmico* ML, orientado a predecir con precisión. Shmueli (2010) formalizó esta diferencia entre *explanatory modeling* y *predictive modeling*. El artículo de Tang et al. (2024) opera en la segunda cultura y emplea SHAP (Lundberg & Lee, 2017), fundamentado en los valores de Shapley de la teoría de juegos cooperativos, para reintroducir interpretabilidad.

El puente entre ambos enfoques es, precisamente, la IA Explicable (XAI). Mediante SHAP, el artículo reintroduce la interpretabilidad en los modelos predictivos, asignando a cada variable una contribución positiva o negativa a la predicción individual. Así, la capacidad predictiva de la IA converge con la vocación explicativa de la Estadística.

La distinción es, por tanto, funcional más que tajante. Varios de los “modelos de ML” empleados (regresión logística, Lasso y Ridge) son métodos estadísticos clásicos, y el propio SHAP se funda en la teoría de juegos cooperativos. En síntesis, Tang et al. (2024) no oponen IA y Estadística: las distinguen por su énfasis, predecir con precisión frente a interpretar relaciones y las articulan mediante la XAI, que opera como mecanismo de traducción entre ambos lenguajes. SHAP devuelve interpretabilidad a un modelo predictivo, situando al artículo en la cultura algorítmica de Breiman (2001) sin renunciar a la vocación explicativa de la Estadística. Más que disciplinas rivales, operan como un continuo: la IA extiende la capacidad predictiva de la Estadística sobre relaciones complejas y no lineales, mientras la Estadística aporta el marco interpretativo. El artículo trata así la IA como una extensión predictiva de la Estadística, no como su antítesis. Esta distinción funcional y no esencial es la que permite, separar lo que el modelo *predice* de lo que efectivamente *explica*.

Pregunta 2

Dado que muchos enfoques de Machine Learning priorizan el rendimiento predictivo, ¿el artículo distingue entre predicción y explicación, o asume que ambos son equivalentes?

Para responder esta pregunta, primero hay que determinar qué definiciones se utilizarán de “explicar” y “predecir”. Predecir tiene una definición según la RAE: “Anunciar por revelación, conocimiento fundado, intuición o conjetura algo que ha de suceder” (RAE, s.f., definición 1). Explicar, en cambio, posee varias definiciones; las pertinentes al artículo a comentar son: “Declarar o exponer cualquier materia, doctrina o texto difícil, con palabras muy claras para hacerlos más perceptibles” (RAE, s.f., definición 2) y “Dar a conocer la causa o motivo de algo” (RAE, s.f., definición 5).

Si se toma en cuenta la primera definición de explicar, el artículo trata predicción y explicación como funcionalmente semejantes. El objetivo de los modelos que analizan una base de datos es predecir eventos futuros (Breiman, 2001, p. 199). La forma en que lo hacen es tomando toda la información disponible y condensándola en los elementos más importantes, presentando de forma simplificada la información total. Esta simplificación puede entenderse como exponer la información de manera que el receptor la comprenda, es decir, los modelos explican la información en el sentido de hacerla perceptible. En pocas palabras, estos modelos predicen y la forma en que predicen es a través de la explicación que le dan a la distribución de los parámetros; por ello, bajo esta definición, predicción y explicación son equivalentes.

En cambio, si se considera la segunda definición de explicar, dar a conocer la causa o motivo de algo, la respuesta difiere. Esta es la distinción que Shmueli (2010) formula entre *explanatory modeling* y *predictive modeling*: explicar consiste en contrastar una hipótesis causal sobre el mecanismo que genera los datos, mientras que predecir consiste en estimar con precisión valores no observados sin requerir que el modelo represente dicho mecanismo. Bajo este marco, el artículo se inscribe claramente en la cultura predictiva: su criterio de éxito es el desempeño ($AUC = 97,05\%$ con Random Forest; Tang et al., 2024, Tabla 1), no la verificación de una hipótesis causal sobre el suicidio. La incorporación de SHAP (Lundberg & Lee, 2017) no altera esta orientación: los valores SHAP atribuyen a cada variable su contribución a la salida del modelo, es decir, explican *el modelo*, no *el fenómeno*. Se trata de interpretabilidad (saber qué variables empujan la predicción) y no de explicación causal (saber por qué ocurre el suicidio).

La distinción es relevante porque las atribuciones SHAP son asociativas y dependen del modelo y de los datos que lo entrenan. Como advierte Pearl (2009), la correlación no implica causalidad: sin un diseño que controle confusores o intervenga sobre las variables, no es posible elevar una asociación predictiva a relación causal. Por ello, que la ira, la depresión y el aislamiento social sean predictores importantes (Tang et al., 2024, Fig. 6b) no equivale a afirmar que los causen; podrían ser síntomas, consecuencias o efectos de un confusor común.

En conclusión, la respuesta depende de la definición de explicar que se adopte. Bajo la primera definición, exponer de forma clara y comprensible, el artículo trata predicción y explicación como equivalentes. Bajo la segunda, dar a conocer la causa, ambos conceptos difieren: el aporte del artículo es predictivo y la XAI cumple una función interpretativa sobre el modelo, mientras que la explicación causal del fenómeno, en el sentido de Shmueli (2010) y Pearl (2009), queda fuera de su diseño.

Pregunta 3

En muchas aplicaciones de Machine Learning, las relaciones identificadas por los modelos están guiadas principalmente por patrones presentes en los datos y por objetivos predictivos, sin una justificación teórica explícita del fenómeno subyacente. ¿Qué evidencia entrega el artículo para justificar que el patrón identificado corresponde al fenómeno estudiado?

Para responder esta pregunta, se evaluarán todas las conclusiones obtenidas relacionadas con el fenómeno investigado y la base que llevó a cada una de ellas.

La primera conclusión: *Quienes fallecen por suicidio tienden a ser personas con trastornos o enfermedades* (Tang et al., 2024, Fig. 1). Esta conclusión se obtiene mediante una nube de palabras formada con la base de datos obtenida; no se entrega otro tipo de información para justificar dicha inferencia. Se trata de una descripción del propio conjunto de datos, no de una hipótesis contrastada sobre el mecanismo que lo genera, distinción que Shmueli (2010) sitúa en el centro del *explanatory modeling*.

La segunda conclusión: *Las personas con altos ingresos y una ocupación respetable presentan menores tasas de suicidio* (Tang et al., 2024, Fig. 2). Se llegó a esta conclusión a través de un gráfico de barras elaborado con la base de datos, el cual mostraba que las personas desempleadas tienen el mayor riesgo de suicidio, mientras que el personal de seguridad y los policías presentan el menor riesgo. También se menciona que la conclusión obtenida coincide con los resultados de otros estudios, aunque no se profundiza en los motivos de la existencia del patrón encontrado; solo se señala que este existe. Como advierte Pearl (2009), la coincidencia entre estudios refuerza la regularidad de la asociación, pero no la eleva a relación causal mientras no se controlen confusores ni se intervenga sobre las variables.

Posteriormente, mediante modelos de predicción, la matriz de correlación y el cálculo de los valores SHAP, se obtiene que factores como tener problemas de ira o depresión pueden aumentar el riesgo de suicidio de los individuos (Tang et al., 2024, Fig. 6b). Por otro lado, factores como un alto nivel educativo disminuyen dicho riesgo (Tang et al., 2024, Fig. 7). Los resultados obtenidos coinciden con las conclusiones anteriores, con la diferencia de que fueron alcanzados mediante métodos más complejos. Sin embargo, a pesar de ofrecer mayor evidencia a través de los valores SHAP, estos se calculan utilizando la misma base de datos, por lo que continúa el patrón de basar las conclusiones únicamente en ella. Esta dependencia se acentúa porque incluso la ampliación de la muestra se genera con técnicas de aumento de datos (CTGAN y SMOTENC) que sintetizan registros a partir de la distribución original (Chawla et al., 2002; Xu et al., 2019); en consecuencia, las atribuciones SHAP describen el modelo, la cultura predictiva de Breiman (2001), y no el mecanismo del fenómeno.

El análisis se limita a observar los registros y explicarlos mediante distintos modelos predictivos, sin ampliar su perspectiva. Ninguno de los apartados que presenta estas conclusiones las justifica desde un punto de vista psicológico o psiquiátrico, el cual podría complementar los resultados y mejorar la aplicación de estos modelos, dado que serían utilizados en el área médica. En términos de Shmueli (2010) y Pearl (2009), el artículo aporta evidencia de un patrón estable y útil para predecir, pero no una justificación teórico-causal que lo vincule al fenómeno más allá del conjunto de datos. Es importante mencionar por ello, que el artículo se muestra consciente de esta limitación, y concluye que los modelos de predicción deberían ser utilizados en conjunto con el asesoramiento médico (Tang et al., 2024, Clinical Implications and Future Directions).

En conclusión, los modelos de Machine Learning proveen solo una explicación de los registros obtenidos, y por ello deberían ser utilizado como complemento y validación al juicio médico.

Referencias

1. Breiman, L. (2001). *Statistical Modeling: The Two Cultures*. *Statistical Science*, 16(3), 199–231.
<https://projecteuclid.org/journals/statistical-science/volume-16/issue-3/Statistical-Modeling--The-Two-Cultures-with-comments-and-a/10.1214/ss/1009213726.pdf>
2. Shmueli, G. (2010). *To Explain or to Predict?* *Statistical Science*, 25(3), 289–310.
<https://www.stat.berkeley.edu/~aldous/157/Papers/shmueli.pdf>
3. Lundberg, S. M., & Lee, S.-I. (2017). *A Unified Approach to Interpreting Model Predictions*. *Advances in Neural Information Processing Systems* (NeurIPS).
<https://proceedings.neurips.cc/paper/7062-a-unified-approach-to-interpreting-model-predictions.pdf>
4. Pearl, J. (2009). *Causality: Models, Reasoning, and Inference* (2.^a ed.). Cambridge University Press.
https://archive.illc.uva.nl/cil/uploaded_files/inlineitem/Pearl_2009_Causality.pdf
5. Chawla, N. V., Bowyer, K. W., Hall, L. O., & Kegelmeyer, W. P. (2002). *SMOTE: Synthetic Minority Over-sampling Technique*. *Journal of Artificial Intelligence Research*, 16, 321–357.
<https://arxiv.org/pdf/1106.1813>
6. Xu, L., Skoularidou, M., Cuesta-Infante, A., & Veeramachaneni, K. (2019). *Modeling Tabular Data using Conditional GAN*. *Advances in Neural Information Processing Systems* (NeurIPS).
<https://arxiv.org/pdf/1907.00503>
7. Tang, H., Miri Rekavandi, A., Rooprai, D., Dwivedi, G., Sanfilippo, F. M., Boussaid, F., & Bennamoun, M. (2024). *Analysis and evaluation of explainable artificial intelligence on suicide risk assessment*. *Scientific Reports*, 14, 6163.
<https://www.nature.com/articles/s41598-024-53426-0.pdf>
8. Real Academia Española. (s.f.). *Explicar*. En *Diccionario de la lengua española* (edición del tricentenario).
<https://dle.rae.es/explicar>
9. Real Academia Española. (s.f.). *Predecir*. En *Diccionario de la lengua española* (edición del tricentenario).
<https://dle.rae.es/predecir>