



FACULTAD DE MATEMÁTICAS
PONTIFICIA UNIVERSIDAD
CATÓLICA DE CHILE

Análisis del Artículo:

*Explainable Artificial Intelligence for Suicide Risk
Assessment Using Register Data*

EYP3507: Bioestadística

Integrantes:

Esteban D. Román

William Mora

Pontificia Universidad Católica de Chile
Facultad de Matemáticas

13 de junio de 2026

Resumen

Este trabajo analiza el artículo de Tang et al. (2024), que evalúa el uso de Inteligencia Artificial Explicable (XAI) para predecir el riesgo de suicidio a partir de datos tabulares de registro médico. La motivación de los autores parte de una limitación reconocida en el área: las herramientas tradicionales de evaluación del riesgo, basadas mayoritariamente en escalas autoinformadas y juicio clínico, presentan un valor predictivo positivo bajo y resultan insuficientes para estratificar con precisión a los pacientes (Tang et al., 2024, Introducción). Frente a ello, el artículo propone combinar modelos de aprendizaje automático con un marco de explicabilidad que permita a los profesionales de la salud mental comprender y confiar en las predicciones.

El objetivo de este informe es responder tres preguntas sobre dicho artículo: (i) la distinción conceptual entre Inteligencia Artificial y Estadística; (ii) si el artículo separa de manera explícita la predicción de la explicación; y (iii) qué evidencia respalda que el patrón identificado por el modelo corresponde efectivamente al fenómeno estudiado y no a un mero artefacto de los datos.

Los datos provienen del historial clínico de pacientes del Colombo South Teaching Hospital (Sri Lanka) y conforman un conjunto balanceado de 1000 registros (500 casos positivos y 500 negativos) con 19 variables predictoras de naturaleza numérica y categórica (Tang et al., 2024, Método, p. 8). Sobre esta base, el artículo aplica dos técnicas de aumento de datos (CTGAN y SMOTENC) para expandir la muestra de entrenamiento y mitigar el sobreajuste, y entrena seis modelos de Machine Learning (Regresión Logística, Árbol de Decisión, Random Forest, SVM, Perceptrón y XGBoost). Random Forest obtiene el mejor desempeño, alcanzando un AUC de 97,05 % tras el aumento de datos (Tang et al., 2024, Tabla 1). Para interpretar el modelo, los autores recurren a los valores SHAP, que identifican la ira, la depresión y el aislamiento social como los predictores principales del riesgo de suicidio (Tang et al., 2024, Fig. 6b).

Concluimos que el artículo trata la XAI como un puente entre la capacidad predictiva del aprendizaje automático y la vocación explicativa de la Estadística. No obstante, conviene precisar el alcance de ese puente: la “explicación” que ofrece SHAP es una atribución de importancia a las variables (es decir, una descripción de cómo cada atributo contribuye a la salida del modelo), y no una explicación causal del suicidio. El método identifica asociaciones predictivas, pero no establece mecanismos causales ni descarta confusores, distinción que resulta central para las tres preguntas que guían este informe.

Pregunta 1

¿Qué distingue conceptualmente a la Inteligencia Artificial o «IA» de la Estadística en este artículo?

El artículo no presenta la Inteligencia Artificial (IA) y la Estadística como disciplinas opuestas, sino que las distingue por su finalidad. La Estadística busca inferir asociaciones e interpretar las relaciones entre variables, mientras que la IA, a través del aprendizaje automático (ML), prioriza la predicción de un resultado a partir de datos históricos.

En el estudio, la Estadística se materializa en el análisis de correlación de Spearman y en el mapa de calor, herramientas orientadas a cuantificar y ordenar la asociación entre variables; por ejemplo, la fuerte correlación entre el suicidio y los problemas de ira, el aislamiento social o la depresión (Tang et al., 2024, Fig. 3). Su valor reside en la interpretabilidad directa: cada coeficiente revela la dirección y la fuerza de una relación sin requerir explicaciones adicionales.

La IA, en cambio, se expresa en modelos como Random Forest y XGBoost, evaluados por su desempeño predictivo ($AUC = 97,05\%$, F1 y precisión; Tang et al., 2024, Tabla 1). Estos modelos capturan relaciones complejas y no lineales que las técnicas clásicas no logran modelar (el artículo advierte que los métodos matemáticos tradicionales producen resultados menos precisos ante la complejidad del comportamiento humano), pero operan como cajas negras de baja interpretabilidad.

Esta tensión no es exclusiva del artículo. Breiman (2001) describió «dos culturas» del modelamiento: la del *modelo de datos* estadística clásica, orientada a inferir la relación entre variables y la del *modelo algorítmico* ML, orientado a predecir con precisión. Shmueli (2010) formalizó esta diferencia entre *explanatory modeling* y *predictive modeling*. El artículo de Tang et al. (2024) opera en la segunda cultura y emplea SHAP (Lundberg & Lee, 2017), fundamentado en los valores de Shapley de la teoría de juegos cooperativos, para reintroducir interpretabilidad.

Mediante SHAP, el artículo reintroduce la interpretabilidad en los modelos predictivos, asignando a cada variable una contribución positiva o negativa a la predicción individual. Así, la capacidad predictiva de la IA converge con la vocación explicativa de la Estadística.

La distinción es, por tanto, funcional más que tajante. Varios de los “modelos de ML” empleados (regresión logística, Lasso y Ridge) son métodos estadísticos clásicos, y el propio SHAP se funda en la teoría de juegos cooperativos. El artículo trata la IA como una extensión predictiva de la Estadística, no como su antítesis.

Pregunta 2: Dado que muchos enfoques de Machine Learning priorizan el rendimiento predictivo, ¿el artículo distingue entre predicción y explicación, o asume que ambos son equivalentes?

Para responder esta pregunta primero hay que determinar qué definiciones hay de *explicar* y *predecir*, y qué definición se utilizará para responder esta pregunta.

Predecir: *“Anunciar por revelación, conocimiento fundado, intuición o conjetura algo que ha de suceder.”*

Explicar: *“Declarar o exponer cualquier materia, doctrina o texto difícil, con palabras muy claras para hacerlos más perceptibles.”*

“Dar a conocer la causa o motivo de algo.”

Si se considera la primera definición, la respuesta es **sí**. Aunque el artículo no realiza una comparación explícita de ambos conceptos, funcionalmente los trata como equivalentes. El objetivo del artículo es presentar los modelos de Inteligencia Artificial Explicable como una forma viable de determinar si un paciente es suicida o no; esto indica que el objetivo de la utilización de estos modelos es la predicción. La forma en que estos modelos predicen es condensando la información de la base de datos en los elementos más importantes y presentándolos de forma simplificada. Desde otra perspectiva, estos modelos exponen la información de modo que el receptor la entienda; es decir, los modelos de Inteligencia Artificial explican la información. En pocas palabras, el objetivo de este tipo de modelos es predecir, y la forma en que predicen incorpora la explicación sobre la distribución de los parámetros.

En cambio, si se considera la segunda definición, la respuesta es **no**. Los modelos de Inteligencia Artificial estudian principalmente correlaciones e interacciones entre parámetros. En estadística, la correlación no implica causalidad; por ello, un análisis correlacional no demuestra la causa de que una persona sea suicida. Para establecer causalidad en psicología se requieren diseños y análisis que controlen el azar y las variables confundentes, algo que los modelos del artículo no garantizan. Por tanto, no es suficiente un análisis exclusivamente basado en IA para indicar causalidad, y se necesitarían análisis adicionales para que el artículo explique las variables.

Pregunta 3

En muchas aplicaciones de Machine Learning, las relaciones identificadas por los modelos están guiadas principalmente por patrones presentes en los datos y por objetivos predictivos, sin una justificación teórica explícita del fenómeno subyacente. ¿Qué evidencia entrega el artículo para justificar que el patrón identificado corresponde al fenómeno estudiado?

Para responder esta pregunta se evaluarán todas las conclusiones obtenidas relacionadas al fenómeno investigado y la base que llevó a cada conclusión:

La primera conclusión es que aquellos que fallecen por suicidio tienden a ser personas con desordenes o enfermedades. La conclusión se obtiene mediante una nube de palabras formada con la base de datos obtenida; no se entrega otro tipo de información que justifique la inferencia.

La segunda conclusión fue que la gente con altos ingresos y una vocación respetable tienen menor tasa de suicidios. Se llegó a esta conclusión a través de un gráfico de barras de la base de datos que mostraba que la gente desempleada tiene el mayor riesgo de suicidio, y el personal de seguridad y policías tienen el menor riesgo. Se menciona también que la conclusión obtenida coincide con el resultado de otros estudios, aunque no profundiza en los motivos de la existencia del patrón encontrado.

Posteriormente, mediante modelos de predicción, la matriz de correlación y el cálculo de los valores SHAP se obtiene que factores como tener problemas con la ira o depresión pueden aumentar el riesgo de suicidio de los individuos. Por otro lado, factores como un alto nivel de educación disminuyen el riesgo. A pesar de ofrecer mayor evidencia en la forma de los valores SHAP, estos se calculan en la misma base de datos, por lo que las conclusiones dependen de esa fuente.

El análisis se limita a observar los registros y explicarlos mediante distintos modelos predictivos sin extender su visión. Ninguno de los apartados que entrega estas conclusiones las justifica mediante el punto de vista psicológico o psiquiátrico, el cual podría complementar los resultados y mejorar la aplicación de estos modelos en el área médica.

Referencias

1. Breiman, L. (2001). *Statistical Modeling: The Two Cultures*. *Statistical Science*, 16(3), 199–231.
<https://projecteuclid.org/journals/statistical-science/volume-16/issue-3/Statistical-Modeling--The-Two-Cultures-with-comments-and-a/10.1214/ss/1009213726.pdf>
2. Shmueli, G. (2010). *To Explain or to Predict?* *Statistical Science*, 25(3), 289–310.
<https://www.stat.berkeley.edu/~aldous/157/Papers/shmueli.pdf>
3. Lundberg, S. M., & Lee, S.-I. (2017). *A Unified Approach to Interpreting Model Predictions*. *Advances in Neural Information Processing Systems* (NeurIPS).
<https://proceedings.neurips.cc/paper/7062-a-unified-approach-to-interpreting-model-predictions.pdf>
4. Pearl, J. (2009). *Causality: Models, Reasoning, and Inference* (2.^a ed.). Cambridge University Press.
https://archive.illc.uva.nl/cil/uploaded_files/inlineitem/Pearl_2009_Causality.pdf
5. Chawla, N., Bowyer, K., Hall, L., & Kegelmeyer, W. (2002). *SMOTE: Synthetic Minority Over-sampling Technique*. *Journal of Artificial Intelligence Research*, 16, 321–357.
<https://arxiv.org/pdf/1106.1813>
6. Xu, L., Skoularidou, M., Cuesta-Infante, A., & Veeramachaneni, K. (2019). *Modeling Tabular Data using Conditional GAN*. *Advances in Neural Information Processing Systems* (NeurIPS).
<https://arxiv.org/pdf/1907.00503>
7. Tang, X., et al. (2024). *Analysis and evaluation of explainable artificial intelligence on suicide risk assessment*. *Scientific Reports*, 14, 6163.
<https://www.nature.com/articles/s41598-024-53426-0.pdf>