



FACULTAD DE MATEMÁTICAS
PONTIFICIA UNIVERSIDAD
CATÓLICA DE CHILE

Análisis del Artículo:

*Explainable Artificial Intelligence for Suicide Risk
Assessment Using Register Data*

EYP3507: Bioestadística

Integrantes:

Esteban D. Román

William Mora

Pontificia Universidad Católica de Chile
Facultad de Matemáticas

14 de junio de 2026

Resumen

Este trabajo analiza el artículo de Tang et al. (2024), que evalúa el uso de Inteligencia Artificial Explicable (XAI) para predecir el riesgo de suicidio a partir de datos tabulares de registro médico. La motivación de los autores parte de una limitación reconocida en el área: las herramientas tradicionales de evaluación del riesgo, basadas mayoritariamente en escalas autoinformadas y juicio clínico, presentan un valor predictivo positivo bajo y resultan insuficientes para estratificar con precisión a los pacientes (Tang et al., 2024, Introducción). Frente a ello, el artículo propone combinar modelos de aprendizaje automático con un marco de explicabilidad que permita a los profesionales de la salud mental comprender y confiar en las predicciones.

El objetivo de este informe es responder tres preguntas sobre dicho artículo: (i) la distinción conceptual entre Inteligencia Artificial y Estadística; (ii) si el artículo separa de manera explícita la predicción de la explicación; y (iii) qué evidencia respalda que el patrón identificado por el modelo corresponde efectivamente al fenómeno estudiado y no a un mero artefacto de los datos.

Los datos provienen del historial clínico de pacientes del Colombo South Teaching Hospital (Sri Lanka) y conforman un conjunto balanceado de 1000 registros (500 casos positivos y 500 negativos) con 19 variables predictoras de naturaleza numérica y categórica (Tang et al., 2024, Método, p. 8). Sobre esta base, el artículo aplica dos técnicas de aumento de datos (CTGAN y SMOTENC) para expandir la muestra de entrenamiento y mitigar el sobreajuste, y entrena seis modelos de Machine Learning (Regresión Logística, Árbol de Decisión, Random Forest, SVM, Perceptrón y XGBoost). Random Forest obtiene el mejor desempeño, alcanzando un AUC de 97,05 % tras el aumento de datos (Tang et al., 2024, Tabla 1). Para interpretar el modelo, los autores recurren a los valores SHAP, que identifican la ira, la depresión y el aislamiento social como los predictores principales del riesgo de suicidio (Tang et al., 2024, Fig. 6b).

Concluimos que el artículo trata la XAI como un puente entre la capacidad predictiva del aprendizaje automático y la vocación explicativa de la Estadística. No obstante, conviene precisar el alcance de ese puente: la “explicación” que ofrece SHAP es una atribución de importancia a las variables (es decir, una descripción de cómo cada atributo contribuye a la salida del modelo), y no una explicación causal del suicidio. El método identifica asociaciones predictivas, pero no establece mecanismos causales ni descarta confusores, distinción que resulta central para las tres preguntas que guían este informe.

Pregunta 1: ¿Qué distingue conceptualmente a la Inteligencia Artificial o «IA» de la Estadística en este artículo?

El artículo no presenta la Inteligencia Artificial (IA) y la Estadística como disciplinas opuestas, sino que las distingue por su finalidad. La Estadística busca inferir asociaciones e interpretar las relaciones entre variables, mientras que la IA, a través del aprendizaje automático (ML), prioriza la predicción de un resultado a partir de datos históricos.

En el estudio, la Estadística se materializa en el análisis de correlación de Spearman y en el mapa de calor, herramientas orientadas a cuantificar y ordenar la asociación entre variables; por ejemplo, la fuerte correlación entre el suicidio y los problemas de ira, el aislamiento social o la depresión (Tang et al., 2024, Fig. 3). Su valor reside en la interpretabilidad directa: cada coeficiente revela la dirección y la fuerza de una relación sin requerir explicaciones adicionales.

La IA, en cambio, se expresa en modelos como Random Forest y XGBoost, evaluados por su desempeño predictivo ($AUC = 97,05\%$, F1 y precisión; Tang et al., 2024, Tabla 1). Estos modelos capturan relaciones complejas y no lineales que las técnicas clásicas no logran modelar (el artículo advierte que los métodos matemáticos tradicionales producen resultados menos precisos ante la complejidad del comportamiento humano), pero operan como cajas negras de baja interpretabilidad.

Esta tensión no es exclusiva del artículo. Breiman (2001) describió «dos culturas» del modelamiento: la del *modelo de datos* estadística clásica, orientada a inferir la relación entre variables y la del *modelo algorítmico* ML, orientado a predecir con precisión. Shmueli (2010) formalizó esta diferencia entre *explanatory modeling* y *predictive modeling*. El artículo de Tang et al. (2024) opera en la segunda cultura y emplea SHAP (Lundberg & Lee, 2017), fundamentado en los valores de Shapley de la teoría de juegos cooperativos, para reintroducir interpretabilidad.

El puente entre ambos enfoques es, precisamente, la IA Explicable (XAI). Mediante SHAP, el artículo reintroduce la interpretabilidad en los modelos predictivos, asignando a cada variable una contribución positiva o negativa a la predicción individual. Así, la capacidad predictiva de la IA converge con la vocación explicativa de la Estadística.

La distinción es, por tanto, funcional más que tajante. Varios de los “modelos de ML” empleados (regresión logística, Lasso y Ridge) son métodos estadísticos clásicos, y el propio SHAP se funda en la teoría de juegos cooperativos. El artículo trata la IA como una extensión predictiva de la Estadística, no como su antítesis.

Pregunta 2: Dado que muchos enfoques de Machine Learning priorizan el rendimiento predictivo, ¿el artículo distingue entre predicción y explicación, o asume que ambos son equivalentes?

Para responder esta pregunta primero hay que determinar qué definiciones hay de “explicar” y “predecir”, y que definición se utilizará para responder esta pregunta.

Predecir tiene una definición según la RAE, y esta es “*Anunciar por revelación, conocimiento fundado, intuición o conjetura algo que ha de suceder.*” (s.f., definición 1)

Explicar, por otra parte, tiene varias definiciones según la RAE, se considerarán las definiciones que pertinentes al artículo a comentar, estas son; “*Declarar o exponer cualquier materia, doctrina o texto difícil, con palabras muy claras para hacerlos más perceptibles.*” (s.f., definición 2) “*Dar a conocer la causa o motivo de algo.*” (s.f., definición 5)

Si se toma en cuenta la primera definición de explicar, la respuesta es que se considera semejante a predecir. Si bien no realiza una comparación directa de ambos conceptos, funcionalmente los trata como equivalentes. Es importante dejar en claro que el objetivo de los modelos que analizan una base de datos es predecir los eventos futuros (Breiman, 2001, p. 199). La forma en que estos modelos predicen es tomando toda la información de la base de datos y condensarla a los elementos más importantes de ella, presentando de forma simplificada la información total. Esta simplificación puede entenderse como exponer la información de manera que el receptor la entienda, es decir los modelos de Inteligencia Artificial explican la información. En pocas palabras, el objetivo de este tipo de modelos es predecir y la forma en que predice es con la explicación que le da a la distribución de los parámetros, por ello los modelos de Inteligencia Artificial predicen y explican.

En cambio, si se considera la segunda definición de explicar, la respuesta es que esta difiere a la definición predecir. La razón es que los modelos de Inteligencia Artificial estudian a través de la correlación y la interacción entre sus parámetros. En la estadística, una idea que considerar es que la correlación no necesariamente implica causalidad, y por ello no necesariamente al analizar la base de datos se está entregando la causa de que una persona sea suicida (Pearl, 2009). Para determinar causalidad en la psicología es necesario, entre otros requisitos, descartar la posibilidad de que los resultados sean dados por azar y tener plausibilidad psicológica (Gómez-Restrepo et al. 2006). Dado todos los modelos utilizados poseen un margen de error, eso implica que existe cierto nivel de incerteza o azar al hacer las predicciones. Entonces, no es suficiente un análisis desarrollado por la Inteligencia Artificial para indicar causalidad, y en ese caso se necesitaría otro tipo de análisis extra para que el artículo explique las variables. Por ello los modelos utilizados se limitarían a predecir y no a explicar.

En conclusión, a diferencia de predecir el cual por definición se encuentra en los modelos estadísticos (Breiman, 2001), explicar depende de la definición de este para afirmar que los métodos utilizados explican la base de datos.

Pregunta 3: En muchas aplicaciones de Machine Learning, las relaciones identificadas por los modelos están guiadas principalmente por patrones presentes en los datos y por objetivos predictivos, sin una justificación teórica explícita del fenómeno subyacente. ¿Qué evidencia entrega el artículo para justificar que el patrón identificado corresponde al fenómeno estudiado?

Para responder esta pregunta, se evaluarán todas las conclusiones obtenidas relacionadas con el fenómeno investigado y la base que llevó a cada una de ellas.

Primera conclusión: *Quienes fallecen por suicidio tienden a ser personas con trastornos o enfermedades.* Esta conclusión se obtiene mediante una nube de palabras formada con la base de datos; no se entrega otro tipo de información que justifique dicha inferencia.

Segunda conclusión: *Las personas con altos ingresos y una ocupación respetable presentan menores tasas de suicidio.* Se llegó a esta conclusión a través de un gráfico de barras elaborado con la base de datos, el cual mostraba que las personas desempleadas tienen el mayor riesgo de suicidio, mientras que el personal de seguridad y los policías presentan el menor riesgo. También se menciona que la conclusión obtenida coincide con los resultados de otros estudios, aunque no se profundiza en los motivos de la existencia del patrón encontrado; solo se señala que este existe.

Posteriormente, mediante modelos de predicción, la matriz de correlación y el cálculo de los valores *SHAP*, se obtiene que factores como tener problemas de ira o depresión pueden aumentar el riesgo de suicidio de los individuos. Por otro lado, factores como un alto nivel educativo disminuyen dicho riesgo. Los resultados obtenidos coinciden con las conclusiones anteriores, con la diferencia de que fueron alcanzados mediante métodos más complejos. Sin embargo, a pesar de ofrecer mayor evidencia a través de los valores *SHAP*, estos se calculan utilizando la misma base de datos, por lo que continúa el patrón de basar las conclusiones únicamente en ella.

Limitaciones y observaciones: El análisis se limita a observar los registros y explicarlos mediante distintos modelos predictivos, sin ampliar su perspectiva. Ninguno de los apartados que presenta estas conclusiones las justifica desde un punto de vista psicológico o psiquiátrico, el cual podría complementar los resultados y mejorar la aplicación de estos modelos en el área médica. **Es importante mencionar**, por ello, que el artículo reconoce esta limitación y concluye que los modelos de predicción deberían ser utilizados en conjunto con el asesoramiento médico.

Referencias

1. Breiman, L. (2001). *Statistical Modeling: The Two Cultures*. *Statistical Science*, 16(3), 199–231.
<https://projecteuclid.org/journals/statistical-science/volume-16/issue-3/Statistical-Modeling--The-Two-Cultures-with-comments-and-a/10.1214/ss/1009213726.pdf>
2. Shmueli, G. (2010). *To Explain or to Predict?* *Statistical Science*, 25(3), 289–310.
<https://www.stat.berkeley.edu/~aldous/157/Papers/shmueli.pdf>
3. Lundberg, S. M., & Lee, S.-I. (2017). *A Unified Approach to Interpreting Model Predictions*. *Advances in Neural Information Processing Systems* (NeurIPS).
<https://proceedings.neurips.cc/paper/7062-a-unified-approach-to-interpreting-model-predictions.pdf>
4. Pearl, J. (2009). *Causality: Models, Reasoning, and Inference* (2.^a ed.). Cambridge University Press.
https://archive.illc.uva.nl/cil/uploaded_files/inlineitem/Pearl_2009_Causality.pdf
5. Chawla, N., Bowyer, K., Hall, L., & Kegelmeyer, W. (2002). *SMOTE: Synthetic Minority Over-sampling Technique*. *Journal of Artificial Intelligence Research*, 16, 321–357.
<https://arxiv.org/pdf/1106.1813>
6. Xu, L., Skoularidou, M., Cuesta-Infante, A., & Veeramachaneni, K. (2019). *Modeling Tabular Data using Conditional GAN*. *Advances in Neural Information Processing Systems* (NeurIPS).
<https://arxiv.org/pdf/1907.00503>
7. Tang, X., et al. (2024). *Analysis and evaluation of explainable artificial intelligence on suicide risk assessment*. *Scientific Reports*, 14, 6163.
<https://www.nature.com/articles/s41598-024-53426-0.pdf>