



FACULTAD DE MATEMÁTICAS
PONTIFICIA UNIVERSIDAD
CATÓLICA DE CHILE

Análisis del Artículo: Tang et al. (2024)

**Analysis and Evaluation of Explainable Artificial
Intelligence on Suicide Risk Assessment**

Esteban D. Román Soto William E. Mora Estrada

Contenido

- ① Contexto del Artículo
- ② P1 — IA vs. Estadística
- ③ P2 — Predicción vs. Explicación
- ④ P3 — Validez del patrón
- ⑤ Conclusiones

El artículo analizado

Tang et al. (2024) — Scientific Reports

Motivación

- Las escalas tradicionales de evaluación del riesgo presentan **bajo valor predictivo positivo**.
- El juicio clínico resulta insuficiente para estratificar con precisión a los pacientes.
- Propuesta: combinar **ML** con un marco de **explicabilidad (XAI)**.

Datos

- Colombo South Teaching Hospital (Sri Lanka).
- 1 000 registros balanceados (500 casos / 500 controles).
- 19 variables predictoras numéricas y categóricas.

Modelos aplicados


- Regresión Logística
- Árbol de Decisión
- **Random Forest** ★
- SVM
- Perceptrón
- XGBoost

Mejor resultado

AUC = 97,05 %
Random Forest + SMOTENC

Metodología del estudio

Flujo de trabajo de Tang et al. (2024)




XAI (nota)

Valores SHAP y discusión interpretativa se presentan en la sección de definiciones y resultados, para mantener el flujo metodológico claro.

Aumento de observaciones

CTGAN y SMOTENC para balanceo de datos



Pregunta 1

¿Qué distingue conceptualmente a la IA de la Estadística en este artículo?

Estadística

- Inferir asociaciones e **interpretar** relaciones entre variables.
- Correlación de Spearman, mapas de calor.
- Interpretabilidad **directa**: cada coeficiente revela dirección y fuerza.

IA / Machine Learning


- Priorizar la **predicción** a partir de datos históricos.
- Random Forest, XGBoost: capturan relaciones no lineales.
- Operan como **caja negra**: baja interpretabilidad.

Marco teórico de referencia

- **Breiman (2001)**: *dos culturas* — modelo de datos vs. modelo algorítmico.
- **Shmueli (2010)**: *explanatory modeling vs. predictive modeling*.

Análisis de correlaciones

Correlación de Spearman entre variables



Interpretación estadística

Las correlaciones permiten identificar relaciones lineales entre variables antes de aplicar modelos de ML.

XAI como puente entre las dos culturas


Pregunta 1 — Conclusión



- La distinción es **funcional**, no esencial: la Regresión Logística es a la vez ML y estadística clásica.
- **SHAP** (basado en la teoría de Shapley) reintroduce interpretabilidad en el modelo predictivo.
- Tang et al. (2024) trata la IA como una **extensión predictiva** de la Estadística, no como su antítesis.

Valores SHAP — Múltiples variables

Importancia de características según SHAP



Interpretabilidad del modelo

SHAP cuantifica la contribución de cada variable a la predicción, revelando qué factores son más determinantes.

Definiciones

Predecir (RAE, def. 1)

«Anunciar por **conocimiento fundado** algo que ha de suceder.»

Explicar — def. 2 (expositiva)

«Declarar una materia con palabras claras para hacerla **más perceptible**.»

Explicar — def. 5 (causal)

«Dar a conocer la **causa o motivo** de algo.»

Pregunta 2 — Punto de partida

¿El artículo distingue entre predicción y explicación?

Contexto

El artículo aplica XAI para interpretar modelos predictivos; aquí discutimos si esa interpretación equivale a explicar el fenómeno.

SHAP explica el modelo, no el fenómeno

Atribuye contribuciones a las variables **dentro del modelo**. No establece mecanismos causales.

Definición 1 — Conclusión

Predecir (RAE, def. 1)

Conclusión

Bajo la definición 1 (predecir): la predicción puede aproximarse a una explicación expositiva. SHAP aporta interpretabilidad del modelo, pero no inferencia causal.

Predicción $\neq$ Explicación causal

Pregunta 2 — Marco de Shmueli (2010) y Pearl (2009)

- **Shmueli (2010):** el artículo se inscribe en la cultura *predictiva*: su criterio de éxito es el desempeño ($AUC = 97,05\%$), no la verificación de una hipótesis causal.
- **Pearl (2009):** la correlación no implica causalidad. Sin un diseño que controle confusores, no es posible elevar una asociación predictiva a relación causal.

Consecuencia práctica

Que **ira, depresión y aislamiento social** sean los predictores más importantes **no equivale a afirmar que los causen**. Podrían ser síntomas, consecuencias o efectos de un confusor común.

Conclusión de la P2

Bajo definición expositiva: predicción $\approx$ explicación. Bajo definición causal: **difieren**. La XAI interpreta *el modelo*, no el fenómeno.

Pregunta 3 — Evidencia presentada

¿Qué justifica que el patrón corresponde al fenómeno y no a un artefacto?

Evidencia descriptiva

- **Conclusión 1:** nube de palabras $\Rightarrow$ asociación con trastornos.
- **Conclusión 2:** gráfico de barras $\Rightarrow$ desempleo = mayor riesgo.
- Coincide con otros estudios de la literatura.

Evidencia del modelo

- Correlación de Spearman + mapa de calor.
- Random Forest + SHAP $\Rightarrow$ ira, depresión, aislamiento.
- CTGAN/SMOTENC $\Rightarrow$ mayor robustez.
- Factor protector: alto nivel educativo.

Limitación central

Todo el análisis usa la **misma base de datos**. El aumento de datos sintetiza registros de la distribución original: las atribuciones SHAP describen **el modelo**, no el mecanismo del fenómeno.

Pregunta 3 — Conclusión

Alcance de la evidencia

✓ Lo que sí respalda la evidencia

- El patrón es **estable** dentro del conjunto de datos.
- Es **útil para predecir** en el mismo dominio.
- Coincide con hallazgos previos de la literatura.

⚠ Lo que queda abierto

- Justificación **teórico-causal** más allá de los datos.
- Perspectiva **psicológica/psiquiátrica** ausente.
- Generalización a otros contextos.

El propio artículo reconoce la limitación

«Los modelos de predicción deben utilizarse **en conjunto con el asesoramiento médico.**»
(Tang et al., 2024, *Clinical Implications and Future Directions*)

Conclusiones generales

- P1** IA y Estadística **no se oponen** en Tang et al. (2024): se distinguen por su énfasis (predecir vs. interpretar) y la XAI actúa como mecanismo de traducción entre ambas.
- P2** La respuesta depende de la definición de “explicar”: bajo la definición *causal*, predicción y explicación **difieren**. SHAP explica el modelo, no el fenómeno.
- P3** La evidencia justifica que el patrón es **estable y predictivo** dentro del marco de datos, pero la justificación teórico-causal queda abierta.

Síntesis

Los modelos de ML deben usarse como **complemento y validación** del juicio médico, no como sustituto.

Referencias I

- ① Breiman, L. (2001). Statistical Modeling: The Two Cultures. *Statistical Science*, 16(3), 199–231.
- ② Shmueli, G. (2010). To Explain or to Predict? *Statistical Science*, 25(3), 289–310.
- ③ Lundberg, S. M., & Lee, S.-I. (2017). A Unified Approach to Interpreting Model Predictions. *NeurIPS*.
- ④ Pearl, J. (2009). *Causality: Models, Reasoning, and Inference* (2.^a ed.). Cambridge University Press.
- ⑤ Chawla, N. V., et al. (2002). SMOTE: Synthetic Minority Over-sampling Technique. *JAIR*, 16, 321–357.
- ⑥ Xu, L., et al. (2019). Modeling Tabular Data using Conditional GAN. *NeurIPS*.

Referencias II

- ⑦ Tang, H., et al. (2024). Analysis and evaluation of explainable artificial intelligence on suicide risk assessment. *Scientific Reports*, 14, 6163.
- ⑧ Real Academia Española. (s.f.). *Explicar / Predecir*. Diccionario de la lengua española.

Gracias por su atención

Preguntas y comentarios



FACULTAD DE MATEMÁTICAS
PONTIFICIA UNIVERSIDAD
CATÓLICA DE CHILE

EYP3507 Bioestadística · Pontificia Universidad Católica de Chile