

Tang et al. (2024)

Analysis and Evaluation of Explainable Artificial Intelligence on Suicide Risk Assessment



FACULTAD DE MATEMÁTICAS
PONTIFICIA UNIVERSIDAD
CATÓLICA DE CHILE

Integrantes:

Esteban D. Román Soto
William E. Mora Estrada

EYP3507: Bioestadística
Facultad de Matemáticas
Pontificia Universidad Católica de Chile

14 de junio de 2026

Contenido

- 1 Contexto del Artículo
- 2 P1 — IA vs. Estadística
- 3 P2 — Predicción vs. Explicación
- 4 P3 — Validez del patrón
- 5 Conclusiones

El artículo analizado

Tang et al. (2024) — Scientific Reports

Motivación

- Las escalas tradicionales de evaluación del riesgo presentan **bajo valor predictivo positivo**.
- El juicio clínico resulta insuficiente para estratificar con precisión a los pacientes.
- Propuesta: combinar **ML** con un marco de **explicabilidad (XAI)**.

Datos

- Colombo South Teaching Hospital (Sri Lanka).
- 1 000 registros balanceados (500 casos / 500 controles).
- 19 variables predictoras numéricas y categóricas.

Modelos aplicados


- Regresión Logística
- Árbol de Decisión
- **Random Forest** ★
- SVM
- Perceptrón
- XGBoost

Mejor resultado

AUC = 97,05 %
Random Forest + SMOTENC

Metodología del estudio

Flujo de trabajo de Tang et al. (2024)



Predictores principales (valores SHAP)

Ira · Depresión · Aislamiento social

Pregunta 1

¿Qué distingue conceptualmente a la IA de la Estadística en este artículo?

Estadística

- Inferir asociaciones e **interpretar** relaciones entre variables.
- Correlación de Spearman, mapas de calor.
- Interpretabilidad **directa**: cada coeficiente revela dirección y fuerza.

IA / Machine Learning

- Priorizar la **predicción** a partir de datos históricos.
- Random Forest, XGBoost: capturan relaciones no lineales.
- Operan como **caja negra**: baja interpretabilidad.

Marco teórico de referencia

- **Breiman (2001)**: *dos culturas* — modelo de datos vs. modelo algorítmico.
- **Shmueli (2010)**: *explanatory modeling vs. predictive modeling*.

XAI como puente entre las dos culturas

Pregunta 1 — Conclusión



- La distinción es **funcional**, no esencial: la Regresión Logística es a la vez ML y estadística clásica.
- **SHAP** (basado en la teoría de Shapley) reintroduce interpretabilidad en el modelo predictivo.
- Tang et al. (2024) trata la IA como una **extensión predictiva** de la Estadística, no como su antítesis.

Pregunta 2 — Punto de partida

¿El artículo distingue entre predicción y explicación?

Predecir (RAE, def. 1)

«Anunciar por **conocimiento fundado** algo que ha de suceder.»

Explicar — def. 2 (expositiva)

«Declarar una materia con palabras claras para hacerla **más perceptible**.»
predicción $\approx$ explicación

Explicar — def. 5 (causal)

«Dar a conocer la **causa o motivo** de algo.»
predicción $\neq$ explicación

SHAP explica el modelo, no el fenómeno

Atribuye contribuciones a las variables **dentro del modelo**. No establece mecanismos causales.

Predicción $\neq$ Explicación causal

Pregunta 2 — Marco de Shmueli (2010) y Pearl (2009)

- **Shmueli (2010)**: el artículo se inscribe en la cultura *predictiva*: su criterio de éxito es el desempeño ($AUC = 97,05\%$), no la verificación de una hipótesis causal.
- **Pearl (2009)**: la correlación no implica causalidad. Sin un diseño que controle confusores, no es posible elevar una asociación predictiva a relación causal.

Consecuencia práctica

Que **ira, depresión y aislamiento social** sean los predictores más importantes **no equivale a afirmar que los causen**. Podrían ser síntomas, consecuencias o efectos de un confusor común.

Conclusión de la P2

Bajo definición expositiva: predicción $\approx$ explicación. Bajo definición causal: **difieren**. La XAI interpreta *el modelo*, no el fenómeno.

Pregunta 3 — Evidencia presentada

¿Qué justifica que el patrón corresponde al fenómeno y no a un artefacto?

Evidencia descriptiva

- **Conclusión 1:** nube de palabras $\Rightarrow$ asociación con trastornos.
- **Conclusión 2:** gráfico de barras $\Rightarrow$ desempleo = mayor riesgo.
- Coincide con otros estudios de la literatura.

Evidencia del modelo

- Correlación de Spearman + mapa de calor.
- Random Forest + SHAP $\Rightarrow$ ira, depresión, aislamiento.
- CTGAN/SMOTENC $\Rightarrow$ mayor robustez.
- Factor protector: alto nivel educativo.

Limitación central

Todo el análisis usa la **misma base de datos**. El aumento de datos sintetiza registros de la distribución original: las atribuciones SHAP describen **el modelo**, no el mecanismo del fenómeno.

Pregunta 3 — Conclusión

Alcance de la evidencia

✓ Lo que sí respalda la evidencia

- El patrón es **estable** dentro del conjunto de datos.
- Es **útil para predecir** en el mismo dominio.
- Coincide con hallazgos previos de la literatura.

⚠ Lo que queda abierto

- Justificación **teórico-causal** más allá de los datos.
- Perspectiva **psicológica/psiquiátrica** ausente.
- Generalización a otros contextos.

El propio artículo reconoce la limitación

«Los modelos de predicción deben utilizarse **en conjunto con el asesoramiento médico.**»
(Tang et al., 2024, *Clinical Implications and Future Directions*)

Conclusiones generales

- P1** IA y Estadística **no se oponen** en Tang et al. (2024): se distinguen por su énfasis (predecir vs. interpretar) y la XAI actúa como mecanismo de traducción entre ambas.
- P2** La respuesta depende de la definición de “explicar”: bajo la definición *causal*, predicción y explicación **difieren**. SHAP explica el modelo, no el fenómeno.
- P3** La evidencia justifica que el patrón es **estable y predictivo** dentro del marco de datos, pero la justificación teórico-causal queda abierta.

Síntesis

Los modelos de ML deben usarse como **complemento y validación** del juicio médico, no como sustituto.

Referencias I

- ① Breiman, L. (2001). Statistical Modeling: The Two Cultures. *Statistical Science*, 16(3), 199–231.
- ② Shmueli, G. (2010). To Explain or to Predict? *Statistical Science*, 25(3), 289–310.
- ③ Lundberg, S. M., & Lee, S.-I. (2017). A Unified Approach to Interpreting Model Predictions. *NeurIPS*.
- ④ Pearl, J. (2009). *Causality: Models, Reasoning, and Inference* (2.^a ed.). Cambridge University Press.
- ⑤ Chawla, N. V., et al. (2002). SMOTE: Synthetic Minority Over-sampling Technique. *JAIR*, 16, 321–357.
- ⑥ Xu, L., et al. (2019). Modeling Tabular Data using Conditional GAN. *NeurIPS*.

Referencias II

- ⑦ Tang, H., et al. (2024). Analysis and evaluation of explainable artificial intelligence on suicide risk assessment. *Scientific Reports*, 14, 6163.
- ⑧ Real Academia Española. (s.f.). *Explicar / Predecir*. Diccionario de la lengua española.

Gracias por su atención

Preguntas y comentarios



FACULTAD DE MATEMÁTICAS
PONTIFICIA UNIVERSIDAD
CATÓLICA DE CHILE

EYP3507 Bioestadística · Pontificia Universidad Católica de Chile